

第 9 次作业参考解答

3. 设总体的大小为 N , 总体均值和方差分别为 μ, σ^2 , X_i ($i = 1, \dots, n$) 为无放回抽取的简单随机样本。

• (1) 证明: $\mathbb{E}(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$.

– 期望: 样本 X_i 是从总体中简单随机抽样得到的, 即每个样本来自总体中的任意个体, 且被抽取的概率相等。因此, 单个样本的期望为:

$$\mathbb{E}(X_i) = \mathbb{E}\mathbb{E}[X_i | i^{\text{th}} \text{ is chosen}] = \sum \mathbb{P}(i^{\text{th}} \text{ is chosen}) \cdot X_i = \frac{1}{N} \sum_{i=1}^N X_i = \mu.$$

– 方差: 样本 X_i 的方差为:

$$\text{Var}(X_i) = \mathbb{E}\text{Var}(X_i | i^{\text{th}} \text{ is chosen}) + \text{Var}\mathbb{E}(X_i | i^{\text{th}} \text{ is chosen}) = 0 + \left(\frac{1}{N} \sum_{i=1}^N X_i^2 - \left(\frac{1}{N} \sum_{i=1}^N X_i \right)^2 \right) = \sigma^2.$$

• (2) 证明: $\mathbb{E}(\bar{X}) = \mu$, $\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}$.

样本均值为:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

– 期望: 由于期望的线性性:

$$\mathbb{E}(\bar{X}) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i).$$

结合 (1) 中 $\mathbb{E}(X_i) = \mu$, 得到:

$$\mathbb{E}(\bar{X}) = \frac{1}{n} \cdot n \cdot \mu = \mu.$$

– 方差:

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \text{Cov}(X_i, X_j).$$

在无放回抽样的情况下, 样本之间存在协方差:

$$\text{Cov}(X_i, X_j) = \begin{cases} \sigma^2, & i = j, \\ EX_i X_j - EX_i EX_j = -\frac{\sigma^2}{N-1}, & i \neq j. \end{cases}$$

因为:

$$\begin{aligned}
EX_i X_j &= \sum_{i \neq j} X_i X_j \cdot P(X_i, X_j) = \sum_{i \neq j} X_i X_j \cdot \frac{1}{N(N-1)} \\
&= \frac{1}{N(N-1)} \left(\sum_{i,j} X_i X_j - \sum_{i=j} X_i X_j \right) \\
&= \frac{1}{N(N-1)} \left(\left(\sum_{i=1}^N X_i \right)^2 - \sum_{i=1}^N X_i^2 \right) \\
&= \frac{1}{N(N-1)} (N^2 \mu^2 - N(\sigma^2 + \mu^2)) \\
&= \mu^2 - \frac{1}{N-1} \sigma^2
\end{aligned}$$

因此:

$$\text{Var}(\bar{X}) = \frac{1}{n^2} \left(n \cdot \sigma^2 + n(n-1) \cdot \left(-\frac{\sigma^2}{N-1} \right) \right) = \frac{\sigma^2}{n} \left(1 - \frac{n-1}{N-1} \right) = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}$$

4. 设随机样本 X_i ($i = 1, \dots, n$) 来自二项总体 $B(k, p)$ 。

(1) 给出参数 k 和 p 的矩估计。对于二项分布 $B(k, p)$, 其期望和方差分别为:

$$\mathbb{E}(X) = kp, \quad m_2(X) = kp(1-p).$$

令 $a_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $m_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, 所以:

$$\hat{p} = 1 - \frac{m_2}{a_1}, \quad \hat{k} = \frac{a_1}{\hat{p}}.$$

(2) 尝试讨论上述估计的不足之处。

- 当样本均值 \bar{X} 接近 0 或者存在离群值 (例如 $n = 10, X_1 \dots X_9 = 0, X_{10} = 10$), \hat{p} 为负值。
- 无法保证 ($k > \max_i X_i$)。
- 无法保证 k 为整数
- 并非无偏, 样本量小时偏差较大。

5. 设随机样本 X_i ($i = 1, \dots, n$) 来自均匀分布 $U(\theta, 2\theta)$, 求 θ 的矩估计和极大似然估计。

(1) 矩估计: 对于均匀分布 $U(\theta, 2\theta)$, 其期望为:

$$\mathbb{E}(X) = \frac{\theta + 2\theta}{2} = \frac{3\theta}{2}.$$

设样本均值为 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, 令

$$\frac{3\theta}{2} = \bar{X}.$$

解得:

$$\hat{\theta} = \frac{2}{3} \bar{X}.$$

(2) 极大似然估计:

对于均匀分布 $U(\theta, 2\theta)$, 样本的联合概率密度函数 (pdf) 为:

$$f(X_1, \dots, X_n | \theta) = \left(\frac{1}{\theta}\right)^n I_{[\theta \leq X_{\min}, 2\theta \geq X_{\max}]}$$

其中 $X_{\min} = \min\{X_1, \dots, X_n\}$, $X_{\max} = \max\{X_1, \dots, X_n\}$ 。

$$\theta \leq X_{\min}, \quad 2\theta \geq X_{\max}.$$

要使似然函数最大, θ 应尽可能小, 因此:

$$\hat{\theta}_{\text{MLE}} = \frac{X_{\max}}{2}.$$

Tips 很多同学得到 $\min\{X_{\min}, \frac{X_{\max}}{2}\}$ 结果当然是一样的, 但是不需要比较 (而且我不太明白为什么要这样写, X_{\min} 是上界), 而且在给定题设分布下, $\frac{X_{\max}}{2}$ 必然更小

6. 设函数

$$f(x; a, \sigma) = (\sqrt{2\pi}\sigma^3)^{-1}(x-a)^2 \exp\left(-\frac{1}{2\sigma^2}(x-a)^2\right), \quad x \in \mathbb{R},$$

其中 $a \in \mathbb{R}$, $\sigma > 0$ 为参数。

(1) 验证 $f(x; a, \sigma)$ 作为 x 的函数满足概率密度的归一化要求。需要验证:

$$\int_{-\infty}^{\infty} f(x; a, \sigma) dx = 1.$$

令 $y = \frac{x-a}{\sigma}$, 则 $dy = \frac{dx}{\sigma}$, 并且有:

$$f(x; a, \sigma) = \frac{1}{\sqrt{2\pi}\sigma^3}(x-a)^2 \exp\left(-\frac{1}{2\sigma^2}(x-a)^2\right) = \frac{\sigma^2 y^2}{\sqrt{2\pi}\sigma^3} \exp\left(-\frac{1}{2}y^2\right).$$

积分变为:

$$\int_{-\infty}^{\infty} f(x; a, \sigma) dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^2 e^{-\frac{1}{2}y^2} dy.$$

对 $\int_{-\infty}^{\infty} y^2 e^{-\frac{1}{2}y^2} dy$ 分部积分:

$$\int y^2 e^{-\frac{1}{2}y^2} dy = \left[-ye^{-\frac{1}{2}y^2}\right]_{-\infty}^{\infty} + \int e^{-\frac{1}{2}y^2} dy.$$

1.

$$\left[-ye^{-\frac{1}{2}y^2}\right]_{-\infty}^{\infty} = 0,$$

因为当 $y \rightarrow \pm\infty$, $ye^{-\frac{1}{2}y^2} \rightarrow 0$ 。

2. 由正态分布的归一性:

$$\int_{-\infty}^{\infty} e^{-\frac{1}{2}y^2} dy = \sqrt{2\pi}.$$

因此:

$$\int_{-\infty}^{\infty} y^2 e^{-\frac{1}{2}y^2} dy = \sqrt{2\pi}.$$

代回原式得:

$$\int_{-\infty}^{\infty} f(x; a, \sigma) dx = \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = 1.$$

Tips: 有同学发现 $\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^2 e^{-\frac{1}{2}y^2} dy$ 是标准正态的二阶矩, 即可直接得出是 1)

(2) 设随机样本 X_i ($i = 1, \dots, n$) 来自此总体, 求 a 和 σ^2 的矩估计。

期望:

令 $y = \frac{x-a}{\sigma}$, 则 $x = a + \sigma y$, $dx = \sigma dy$, 积分变为:

$$\begin{aligned} \mathbb{E}(X) &= \int_{-\infty}^{\infty} (a + \sigma y) \cdot \frac{y^2}{\sqrt{2\pi}} e^{-\frac{1}{2}y^2} dy \\ &= a \cdot \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^2 e^{-\frac{1}{2}y^2} dy + \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^3 e^{-\frac{1}{2}y^2} dy \\ &= a \quad (\text{第一部分利用 pdf 归一性, 第二部分为奇函数, 在对称区间上的积分为 } 0) \end{aligned}$$

方差:

$$\mathbb{E}(X^2) = \int_{-\infty}^{\infty} x^2 f(x; a, \sigma) dx.$$

同样令 $y = \frac{x-a}{\sigma}$, 积分变为:

$$\begin{aligned} \mathbb{E}(X^2) &= \int_{-\infty}^{\infty} (a^2 + 2a\sigma y + \sigma^2 y^2) \cdot \frac{y^2}{\sqrt{2\pi}} e^{-\frac{1}{2}y^2} dy. \\ \mathbb{E}(X^2) &= a^2 \cdot \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^2 e^{-\frac{1}{2}y^2} dy + 2a\sigma \cdot \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^3 e^{-\frac{1}{2}y^2} dy + \sigma^2 \cdot \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^4 e^{-\frac{1}{2}y^2} dy. \end{aligned}$$

计算各项:- 第一项: $\int_{-\infty}^{\infty} y^2 e^{-\frac{1}{2}y^2} dy = \sqrt{2\pi}$; - 第二项: $\int_{-\infty}^{\infty} y^3 e^{-\frac{1}{2}y^2} dy = 0$; - 第三项: $\int_{-\infty}^{\infty} y^4 e^{-\frac{1}{2}y^2} dy = 3\sqrt{2\pi}$
(通过分部积分可递归减少 y 的次数)。

因此:

$$\mathbb{E}(X^2) = a^2 + 3\sigma^2.$$

$$\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = (a^2 + 3\sigma^2) - a^2 = 3\sigma^2.$$

矩估计:

$$\hat{a} = a_1 = \bar{X}, \quad \hat{\sigma}^2 = \frac{m_2}{3}.$$

Tips 先计算 $y = \frac{x-a}{\sigma}$ 的方差再变换回 X , 这样计算会更简单

(3) 列出 a, σ^2 的极大似然估计所满足的方程, 并指出一种迭代求解的方法。

样本的对数似然函数为:

$$\ell(a, \sigma^2) = \sum_{i=1}^n \ln f(X_i; a, \sigma) = -n \ln(\sqrt{2\pi}\sigma^3) + \sum_{i=1}^n \ln(X_i - a)^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - a)^2.$$

对 a 和 σ^2 求偏导，令偏导为 0，得到方程组：

$$\frac{\partial \ell}{\partial a} = -2 \sum_{i=1}^n \frac{X_i - a}{(X_i - a)^2} + \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - a) = 0,$$

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{3n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (X_i - a)^2 = 0.$$

迭代方法，例如：

(a) 1. 对 $-\ell(a, \sigma^2)$ Gradient Descent(梯度下降)：

- 目标是最小化负对数似然函数 $-\ell(a, \sigma^2)$ 。
- 更新规则：

$$a^{(t+1)} = a^{(t)} - \eta \frac{\partial(-\ell(a, \sigma^2))}{\partial a}, \quad \sigma_{(t+1)}^2 = \sigma_{(t)}^2 - \eta \frac{\partial(-\ell(a, \sigma^2))}{\partial \sigma^2},$$

其中 η 是学习率，可以设定为自适应减小。

(b) 2. Coordinate Descent 坐标下降：

- 首先利用初始值（如样本均值 \bar{X} 和样本方差 S^2 ）对 a 和 σ^2 进行初始化。
- 固定 a ，求解 σ^2 的更新值：

$$\sigma^2 = \frac{1}{3n} \sum_{i=1}^n (X_i - a)^2.$$

- 固定 σ^2 ，迭代求解 a 。

7. 设随机样本 X_i ($i = 1, \dots, n$) 来自 Bernoulli 总体 $B(p)$ ，请给出参数 p 的矩估计和极大似然估计。

(1) 矩估计：对于 Bernoulli 分布 $B(p)$ ，其期望为：

$$\mathbb{E}(X) = p.$$

设样本均值为 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ，令：

$$p = \bar{X}.$$

因此：

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i.$$

(2) MLE：Bernoulli 分布的 pmf 为：

$$f(X_i; p) = p^{X_i} (1-p)^{1-X_i}, \quad X_i \in \{0, 1\}.$$

对于 X_1, \dots, X_n ，似然函数为：

$$L(p) = \prod_{i=1}^n f(X_i; p) = \prod_{i=1}^n p^{X_i} (1-p)^{1-X_i}.$$

取对数:

$$\ell(p) = \ln L(p) = \sum_{i=1}^n [X_i \ln p + (1 - X_i) \ln(1 - p)].$$

对 p 求导并令其为零:

$$\frac{\partial \ell(p)}{\partial p} = \frac{\sum_{i=1}^n X_i}{p} - \frac{n - \sum_{i=1}^n X_i}{1 - p} = 0.$$

解得:

$$\hat{p} = \frac{\sum_{i=1}^n X_i}{n}.$$

8. 设总体是总数为 n , 单元概率分别为 p_1, \dots, p_m (这里 $p_1 + \dots + p_m = 1$) 的多项分布, X_i ($i = 1, \dots, m$) 分别为 m 个单元的观测频数 ($X_1 + \dots + X_m = n$). 求参数 p_i ($i = 1, \dots, m$) 的极大似然估计。

MLE: 多项分布的 pmf 为:

$$f(X_1, \dots, X_m; p_1, \dots, p_m) = \frac{n!}{X_1! X_2! \dots X_m!} \prod_{i=1}^m p_i^{X_i}.$$

对于样本 X_1, \dots, X_m , 似然函数为:

$$L(p_1, \dots, p_m) = \frac{n!}{X_1! X_2! \dots X_m!} \prod_{i=1}^m p_i^{X_i}.$$

取对数:

$$\ell(p_1, \dots, p_m) = \ln L = \ln \left(\frac{n!}{X_1! X_2! \dots X_m!} \right) + \sum_{i=1}^m X_i \ln p_i.$$

由于第一项不依赖于 p_i , 忽略常数部分, 优化目标为:

$$\ell(p_1, \dots, p_m) = \sum_{i=1}^m X_i \ln p_i.$$

对每个 p_i 求导并加上约束条件 $\sum_{i=1}^m p_i = 1$, 使用拉格朗日乘子法:

$$\mathcal{L}(p_1, \dots, p_m, \lambda) = \sum_{i=1}^m X_i \ln p_i + \lambda \left(1 - \sum_{i=1}^m p_i \right).$$

对 p_i 求偏导数并令其为零:

$$\frac{\partial \mathcal{L}}{\partial p_i} = \frac{X_i}{p_i} - \lambda = 0, \quad i = 1, \dots, m.$$

解得:

$$p_i = \frac{X_i}{n}, \quad i = 1, \dots, m.$$

因此:

$$\hat{p}_i^{MLE} = \frac{X_i}{n}, \quad i = 1, \dots, m.$$

9. 设总体 X 的分布如下:

X	1	2	3
P	θ^2	$2\theta(1-\theta)$	$(1-\theta)^2$

其中 $0 < \theta < 1$ 是未知参数。已知样本值 $x_1 = 1, x_2 = 2, x_3 = 1$, 求 θ 的矩估计值和极大似然估计值。

(1) 矩估计:

$$\begin{aligned}\mathbb{E}(X) &= 1 \cdot \theta^2 + 2 \cdot 2\theta(1-\theta) + 3 \cdot (1-\theta)^2 \\ &= \theta^2 + 4\theta(1-\theta) + 3(1-\theta)^2 \\ &= \theta^2 + 4\theta - 4\theta^2 + 3 - 6\theta + 3\theta^2 \\ &= -2\theta + 3\end{aligned}$$

样本均值为:

$$\bar{X} = \frac{1+2+1}{3} = \frac{4}{3}.$$

令 $\mathbb{E}(X) = \bar{X}$, 得到:

$$-2\theta + 3 = \frac{4}{3}.$$

因此, θ 的矩估计值为:

$$\hat{\theta} = \frac{5}{6}.$$

(2) MLE:

样本的联合概率为:

$$\begin{aligned}L(\theta) &= P(X = x_1) \cdot P(X = x_2) \cdot P(X = x_3) \\ &= \theta^2 \cdot 2\theta(1-\theta) \cdot \theta^2 \\ &= 2\theta^5(1-\theta).\end{aligned}$$

对数似然函数为:

$$\ell(\theta) = \ln L(\theta) = \ln 2 + 5 \ln \theta + \ln(1-\theta).$$

对 θ 求导:

$$\frac{d\ell(\theta)}{d\theta} = \frac{5}{\theta} - \frac{1}{1-\theta}.$$

令导数为零:

$$\frac{5}{\theta} - \frac{1}{1-\theta} = 0,$$

$$\hat{\theta}_{\text{MLE}} = \frac{5}{6}.$$

10. 设随机样本 X_1, \dots, X_n 来自概率密度函数:

$$f(x) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1, \\ 0, & \text{其他.} \end{cases}$$

其中 $\theta > 0$ 是未知参数。

(1) 矩估计:

$$\begin{aligned} \mathbb{E}(X) &= \int_0^1 x \cdot \theta x^{\theta-1} dx \\ &= \theta \left[\frac{x^{\theta+1}}{\theta+1} \right]_0^1 \\ &= \frac{\theta}{\theta+1}. \end{aligned}$$

设样本均值为 \bar{X} , 令 $\mathbb{E}(X) = \bar{X}$, 则:

$$\frac{\theta}{\theta+1} = \bar{X}.$$

因此:

$$\hat{\theta} = \frac{\bar{X}}{1 - \bar{X}}.$$

(2) MLE:

似然函数为:

$$L(\theta) = \prod_{i=1}^n f(X_i) = \prod_{i=1}^n \theta X_i^{\theta-1} = \theta^n \prod_{i=1}^n X_i^{\theta-1}.$$

取对数似然函数:

$$\ell(\theta) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln X_i.$$

对 θ 求导:

$$\frac{d\ell(\theta)}{d\theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln X_i.$$

令导数为零:

$$\frac{n}{\theta} + \sum_{i=1}^n \ln X_i = 0,$$

$$\theta = -\frac{n}{\sum_{i=1}^n \ln X_i}.$$

因此:

$$\hat{\theta}_{\text{MLE}} = -\frac{n}{\sum_{i=1}^n \ln X_i}.$$

11. Python 示例

```
1 import numpy as np
2
3 def generate_binomial_samples(k, p, n, num_trials=1000):
4     """
5     Generate binomial samples and calculate the estimated k and p using method of moments.
6
7     Parameters:
8     - k (int): Number of trials for the binomial distribution.
9     - p (float): Probability of success.
10    - n (int): Number of samples in each experiment.
11    - num_trials (int): Number of repeated trials to observe results.
12
13    Returns:
14    - results (list): List of estimated k and p for each trial.
15    """
16    results = []
17    for _ in range(num_trials):
18        # Generate n samples from B(k, p)
19        samples = np.random.binomial(k, p, n)
20
21        # Method of moments estimation
22        sample_mean = np.mean(samples)
23        sample_var = np.var(samples, ddof=1) # Use ddof=1 for unbiased variance
24
25        # Estimate p and k
26        if sample_var != 0:
27            p_hat = 1 - sample_var / sample_mean
28            k_hat = sample_mean / p_hat
29        else:
30            p_hat = np.nan # Avoid division by zero
31            k_hat = np.nan
```

```

32
33     results.append((k_hat, p_hat))
34     return results
35
36 # Example usage with different scenarios:
37 scenarios = [(10, 0.01, 10), (10, 0.5, 10), (10, 0.01, 1000), (10, 0.5, 1000)]
38 experiment_results = {}
39
40 for k, p, n in scenarios:
41     experiment_results[(k, p, n)] = generate_binomial_samples(k, p, n)
42
43 experiment_results

```

你可以看到有些情况下会产生负数，例如 $(k, p, n) = (10, 0.01, 10)$ ，得到 (k, p) 部分结果：

```

1     ...
2     (-450359962737049.6, -2.220446049250313e-16),
3     (nan, nan),
4     (nan, nan),
5     (1.80000000000000047, 0.11111111111111083),
6     (nan, nan),
7     (nan, nan),
8     (nan, nan),
9     (nan, nan),
10    (1.80000000000000047, 0.11111111111111083),
11    (-0.19999999999999993, -1.0000000000000004),
12    (nan, nan),
13    (-450359962737049.6, -2.220446049250313e-16),
14    (-450359962737049.6, -2.220446049250313e-16),
15    (-450359962737049.6, -2.220446049250313e-16),
16    (-450359962737049.6, -2.220446049250313e-16),
17    (-0.19999999999999993, -1.0000000000000004),
18    (1.80000000000000047, 0.11111111111111083),
19    (-450359962737049.6, -2.220446049250313e-16),
20    (nan, nan),
21    (nan, nan),
22    (-450359962737049.6, -2.220446049250313e-16),
23    (-450359962737049.6, -2.220446049250313e-16),
24    (1.80000000000000047, 0.11111111111111083),
25    ...

```

总结：

- 矩估计能用低阶矩的时候优先用低阶
- 一般认为矩估计用的 m_2 是未修正的 $\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$
- 一个比较普遍的问题，求估计量得到的结果应当是样本的函数，而不是总体参数。例如不应该是 $\hat{\mu} = EX_i$ ，而是 $\hat{\mu} = \bar{X}$
- 关于 MLE，严格上是需要验证二阶导小于 0（Hessian matrix 负定），但是有如下定理，保证对于指数族分布的极值点（且是参数空间内点）就是 MLE（感兴趣可以了解指数族，目前遇到的分布基本都属于指数族），以下定理来源于 陈希孺. 数理统计引论：

引理 2.6.2. 设 Θ 为 \mathbb{R}^k 中的一个开凸集， $f(\theta) = f(\theta_1, \dots, \theta_k)$ 为定义在其上的实函数。对 Θ 中任一点 $\theta = (\theta_1, \dots, \theta_k)$ ， $\frac{\partial f}{\partial \theta_i}$ 和 $\frac{\partial^2 f}{\partial \theta_i \partial \theta_j}$ ($i, j = 1, \dots, k$) 都存在有限且满足

$$-Q(\theta) = \left(-\frac{\partial^2 f}{\partial \theta_i \partial \theta_j} \right)_{k \times k} > 0, \quad (2.6.32)$$

其中 $Q(\theta)$ 为 k 阶方阵，其 (i, j) 元为 $\frac{\partial^2 f}{\partial \theta_i \partial \theta_j}$ 。则：

1* 方程组

$$\frac{\partial f}{\partial \theta_i} = 0, \quad i = 1, \dots, k \quad (2.6.33)$$

在 Θ 内至多只有一组解 θ_0 。

2* 如方程组 (2.6.33) 有解 θ_0 ，则

$$f(\theta_0) = \sup_{\theta \in \Theta} f(\theta). \quad (2.6.34)$$

其中 (2.6.32) 是指数族所满足的