

第七次作业参考解答

1. 对一般的 $X \sim B(n, p)$, $E(X) = np$, $\text{Var}(X) = np(1-p)$ 且:

$$\text{Skewness}(X) = \frac{1-2p}{\sqrt{np(1-p)}}.$$

若 $np \in \mathbb{Z}$, 则进一步有 $\text{Mode}(X) = \text{Median}(X) = np$.

2. (2) 指数分布、泊松分布、均匀分布的矩母函数分别为

$$M(s) = \frac{\lambda}{\lambda - s}$$

$$M(s) = e^{\lambda(e^s - 1)}$$

$$M(s) = \frac{e^{sb} - e^{sa}}{s(b-a)}$$

(3) 若 X 的矩母函数为 $M_X(t)$, 则

$$\text{Skew}(X) = \frac{M_X^{(3)}(0) - 3M_X^{(1)}(0)M_X^{(2)}(0) + 2[M_X^{(1)}(0)]^3}{[M_X^{(2)}(0) - [M_X^{(1)}(0)]^2]^{\frac{3}{2}}},$$

$$\text{Kurt}(X) = \frac{M_X^{(4)}(0) - 4M_X^{(3)}(0)M_X^{(1)}(0) + 6M_X^{(2)}(0)[M_X^{(1)}(0)]^2 - 3[M_X^{(1)}(0)]^4}{[M_X^{(2)}(0) - [M_X^{(1)}(0)]^2]^2}.$$

3. 指数随机变量的相加 $\frac{2}{3}e^{-2x} + 2e^{-3x}$

4. (1) 对任意 $t > 0$, 可验证

$$\lim_{y \rightarrow +\infty} e^{ty} f_Y(y) dy = +\infty$$

故积分 $E(e^{tY})$ 发散; 类似地可验证对 $t < 0$, $E(e^{tY})$ 不存在.

(2) 记 $X \sim \mathcal{N}(\mu, \sigma^2)$ 的矩母函数为 $M_X(t)$, 则 Y 的 n 阶原点矩即 $E(Y^n) = E(e^{nX}) = M_X(n)$.

5. 独立泊松变量相加仍然服从泊松分布

$$M_Y(s) = M_{X_1}(s) * M_{X_2}(s) = e^{(\lambda_1 + \lambda_2)(e^s - 1)}$$

6. 设第一次取到的断点的左侧占全部线段的比例为 X , 第二次取到的断点的左侧占剩余线段的比例为 Y . 则 X, Y 为独立的随机变量且都服从 $[0, 1]$ 上的均匀分布。故

$$f(x) = 1, 0 \leq x \leq 1, \quad f(y) = 1, 0 \leq y \leq 1$$

这样, 二者的期望为 $E(X) = \int_0^1 x dx = \frac{1}{2}$, $E(Y) = \frac{1}{2}$ 。所求的剩余长度为 $(1-X)(1-Y)$ 。

$$E((1-X)(1-Y)) = E(1-X-Y+XY) = 1 - \frac{1}{2} - \frac{1}{2} + \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$$

7. 设 X 为矿工走到安全之处的时间, Y 为矿工第一次选择的门的编号。那么有

$$E(X|Y=1)=2$$

$$E(X|Y=2)=3+E(X)$$

$$E(X|Y=3)=1+E(X)$$

根据重期望公式, 有

$$E(X)=\sum_{y=1}^3 E(X|Y=y)P(Y=y)=\frac{1}{3}(6+2E(x))$$

解得 $E(X)=6$.

或者用类似几何分布的想法, 选中第一个门可以视为成功。

设 X 为矿工走到安全之处的时间, 在第 Z 次选择中选中了第一个门。则

$$\begin{aligned} P(Z=n) &= \frac{1}{3}\left(\frac{2}{3}\right)^{n-1} \\ E(X|Z=n) &= \frac{3+1}{2}(n-1)+2=2n \\ E(X) &= E(E(X|Z=n)) = \sum_{n=1}^{\infty} \left(\frac{2}{3}\right)^n n \\ &= \lim_{n \rightarrow \infty} 6 - (2n+6)\left(\frac{2}{3}\right)^n = 6 \end{aligned}$$

8. 反复应用重期望公式和性质 $E[g(Y)X|Y] = g(Y)E[X|Y]$ 得

$$E[XY] = E[E[XY|X]] = E[XE[Y|X]] = E[X^2], E[Y] = E[E[Y|X]] = E[X],$$

从而 $\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = \text{Var}[X]$.

9. (1)仅要求对离散和连续的情形证明即可.对于 Y 为离散随机变量的情形,由 X, Y 独立知

$$E[Y|X=x] = \sum_i y_i P(Y=y_i|X=x) = \sum_i y_i P(Y=y_i) = E[Y].$$

从而 $E[Y|X] = E[Y]$.

(2)反之不一定成立.令 $X \sim U(0, 1), Y \sim U(-X, X)$,通过计算验证 $E[Y|X] = E[Y] = 0$ 以及 X, Y 不独立.

画一个圆, 要求 (X, Y) 落在 $X^2 + Y^2 = 1$ 的圆上, 此时有

$$E[Y|X] = 0 \quad E[X] = 0$$

但两者不独立, X 的取值会影响 Y 的取值

10. 参考概率导论(Bertsekas,第2版)4.3.1节的证明(Page197),先证明 $\text{Cov}(\hat{Y}, \tilde{Y}) = 0$,再在 $Y = \hat{Y} + \tilde{Y}$ 两边取方差

即可.

$$\begin{aligned}
 \text{Var}(Y) &= E[Y^2] - (E[Y])^2 \\
 &= E[\hat{Y}^2 + 2\hat{Y}\tilde{Y} + \tilde{Y}^2] - (E[\hat{Y}] + E[\tilde{Y}])^2 \\
 &= E[\hat{Y}^2] - E[\hat{Y}]^2 + E[\tilde{Y}^2] - E[\tilde{Y}]^2 + 2E[\hat{Y}\tilde{Y}] - 2E[\hat{Y}]E[\tilde{Y}] \\
 &= \text{Var}[\hat{Y}] + \text{Var}[\tilde{Y}]
 \end{aligned}$$

11. (1)

$$\begin{aligned}
 \text{Var}[Y|X] &= E[(Y - E[Y|X])^2|X] = E[Y^2 - 2YE[Y|X] + E^2[Y|X]|X] \\
 &= E[Y^2|X] - 2E[YE[Y|X]|X] + E^2[Y|X] \\
 &= E[Y^2|X] - 2E^2[Y|X] + E^2[Y|X] = E[Y^2|X] - E^2[Y|X]
 \end{aligned}$$

(2)

$$\begin{aligned}
 \text{Var}[Y] &= E[Y^2] - E^2[Y] \\
 &= E[Y^2] - E[E^2[Y|X]] + E[E^2[Y|X]] - E^2[Y] \\
 &= E[E[Y^2|X] - E^2[Y|X]] + E[E^2[Y|X]] - E[E^2[Y|X]] \\
 &= E[\text{Var}[Y|X]] + \text{Var}[E[Y|X]]
 \end{aligned}$$

12. 对任意分布 (X, Y) , 条件期望 $E[Y|X]$ 是在得到观测 X 下 Y 的最优预测(最小均方误差意义下), 因为成立性质:

$$E[Y|X] = \underset{g(X)}{\operatorname{argmin}} E[(Y - g(X))^2|X]$$

特别地, 若 $f_{(X,Y)}(x, y) = \frac{2}{\pi} \mathbf{1}_{\{x \geq 0, y \geq 0, x^2 + y^2 \leq 1\}}(x, y)$, 计算得

$$\begin{aligned}
 f_X(x) &= \int_0^{\sqrt{1-x^2}} f(x, y) dy = \frac{2}{\pi} \sqrt{1-x^2} \mathbf{1}_{[0,1]}(x) \\
 f_{Y|X}(y|x) &= \frac{1}{\sqrt{1-x^2}} \mathbf{1}_{[0, \frac{1}{\sqrt{1-x^2}}]}(y)
 \end{aligned}$$

$$E[Y|X=x] = \int_{\mathbb{R}} y f_{Y|X}(y|x) dy = \frac{\sqrt{1-x^2}}{2}, E[Y|X=0.5] = \frac{\sqrt{3}}{4}.$$

13. (1)

$$\begin{aligned}
 E[(Y - (aX + b))^2] &= E[Y^2] - 2aE[XY] + a^2E[X^2] + 2abE[X] - 2bE[Y] + b^2 \\
 &= (\mu_2^2 + \sigma_2^2) - 2a(\mu_1\mu_2 + \rho\sigma_1\sigma_2) + a^2(\mu_1^2 + \sigma_1^2) + 2ab\mu_1 - 2b\mu_2 + b^2 \\
 &= (\mu_1^2 + \sigma_1^2)a^2 + 2\mu_1ab + b^2 - 2(\mu_1\mu_2 + \rho\sigma_1\sigma_2)a - 2\mu_2b + \mu_2^2 + \sigma_2^2 \\
 &\triangleq g(a, b)
 \end{aligned}$$

求偏导得到

$$\begin{aligned}
 \frac{\partial g(a, b)}{\partial a} &= 2[(\mu_1^2 + \sigma_1^2)a + \mu_1b - (\mu_1\mu_2 + \rho\sigma_1\sigma_2)] = 0 \\
 \frac{\partial g(a, b)}{\partial b} &= 2(\mu_1a + b - \mu_2) = 0
 \end{aligned}$$

因而 $a = \rho \frac{\sigma_1}{\sigma_2}$, $b = \mu_2 - \rho \mu_1 \frac{\sigma_2}{\sigma_1}$ 时, 是 Y 的最优线性预测。

(2)将第一小问中的a,b代入,得到均方误差为

$$E[(Y - (aX + b))^2] = \sigma_2^2(1 - \rho^2)$$

可以知道当 σ_2^2 趋近于0或者 ρ 趋近于1的时候,该值接近于0。对应的实际解释为:本身随机变量的随机性比较小,或者观测变量与随机变量之间具有强相关性时,观测的均方误差会趋近于0。

(3)这道题实际上是让我们求 $E[Y|X]$

$$E[Y|X] = \int_{-\infty}^{+\infty} f_{Y|X}(y|x)dy = \mu_2 + \frac{\rho\sigma_1}{\sigma_2}(x - \mu_1)$$

而对于最优线性预测得到的 $\hat{Y} = aX + b = \mu_2 + \frac{\rho\sigma_1}{\sigma_2}(x - \mu_1)$,两者相同。

14. (1)

$$E(Y|N) = N\mu$$

$$E(Y) = E(E(Y|N)) = E(N)\mu = a\mu$$

(2)

$$M_N(t) = E(e^{Nt}) = \sum_{n=1}^{\infty} p_n e^{nt}$$

(3)

$$E(e^{Yt}|N) = \prod_{n=1}^N E(e^{X_n t}) = M_X(t)^N$$

$$M_Y(t) = E(e^{Yt}) = E(M_X(t)^N) = \sum_{n=1}^{\infty} p_n M_X(t)^n$$

(4) 此时 X 的矩母函数 $M_X(t) = \frac{\lambda}{\lambda-t}, t < \lambda$.则 Y 的矩母函数为

$$\begin{aligned} M_Y(t) &= \sum_{n=1}^{\infty} (1-p)^{n-1} p \left(\frac{\lambda}{\lambda-t}\right)^n = \frac{p}{1-p} \sum_{n=1}^{\infty} \left(\frac{(1-p)\lambda}{\lambda-t}\right)^n \\ &= \frac{p}{1-p} \frac{\frac{(1-p)\lambda}{\lambda-t}}{1 - \frac{(1-p)\lambda}{\lambda-t}} \\ &= \frac{\lambda p}{\lambda p - t} \end{aligned}$$

(5) 考察 $X_1 + X_2$ 的矩母函数,有

$$\begin{aligned} M_{X_1+X_2}(t) &= E(e^{(X_1+X_2)t}) \\ &= E(e^{X_1 t})E(e^{X_2 t}) \\ &= \left(\frac{\lambda}{\lambda-t}\right)^2 \end{aligned}$$

显然二者的分布不相同。

15. 例子1: 设 $X_i (i = 1, 2, \dots)$ 相互独立且服从标准正态分布, $Y = X_1 + X_2 + \dots + X_N$, 个数 $N \sim P(\lambda)$. 则

$$M_N(t) = e^{\lambda(e^t - 1)}$$

$$M_X(t) = e^{\frac{t^2}{2}}$$

$$M_Y(t) = e^{\lambda(e^{\frac{t^2}{2}} - 1)}$$

假设 $Y \sim N(\mu, \sigma^2)$, 则

$$M_Y(t) = e^{\frac{\sigma^2 t^2}{2} + \mu t}$$

$$\lambda(e^{\frac{t^2}{2}} - 1) = \frac{\sigma^2 t^2}{2} + \mu t$$

而泊松分布的参数 $\lambda > 0$, 关于 t 的指数函数不能写成有限多的多项式相加的形式。上述等式不成立。Y 不是正态分布。

例子2: 取 $X_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$, $Y = \sum_{i=1}^N X_i$, 其中 X_i, N 彼此独立且

$$P(N = 1) = P(N = 2) = \frac{1}{2}.$$

由Q14结论计算得Y的矩母函数 $M_Y(s) = \frac{1}{2} \exp(\frac{1}{2}s^2) + \frac{1}{2} \exp(s^2)$, 可以验证其不是正态分布对应的矩母函数。

16. (1) $E[X_n] = nE[Y] = 0, \text{Var}[X_n] = n\text{Var}[Y] = n$.
(2) 参考 one-dimensional Wiener process 的性质。

作业总结:

- 典型分布的矩母函数。

1. **泊松分布**（参数 λ ）的矩母函数：

$$M_X(t) = \exp(\lambda(e^t - 1))$$

2. **均匀分布**（在区间 $[a, b]$ 上的均匀分布）的矩母函数：

$$M_X(t) = \frac{e^{bt} - e^{at}}{t(b - a)} \quad (t \neq 0)$$

3. **指数分布**（参数 λ ）的矩母函数：

$$M_X(t) = \frac{\lambda}{\lambda - t} \quad \text{for } t < \lambda$$

4. **高斯分布**（均值为 μ ，方差为 σ^2 ）的矩母函数：

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$$

- 矩母函数和均值方差的关系 1. **均值**（ $\mu = \mathbb{E}[X]$ ）由矩母函数的导数计算：

$$\mu = M'_X(0)$$

2. **方差**（ $\sigma^2 = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$ ）由矩母函数的二阶导数计算：

$$\sigma^2 = M''_X(0) - (M'_X(0))^2$$

- 重期望公式的灵活应用：描述了条件期望与总体期望之间的关系：

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]]$$